

# Servicios Multimedia

## VoIP



Grupo de Tecnología Electrónica y  
Comunicaciones



UNIVERSIDADE DA CORUÑA

UNIVERSIDADE DA CORUÑA

- VoIP (Voice-over-IP)

- Objetivo: utilizar la red de datos para realizar llamadas de voz (y video).  
(el transmisor es el dispositivo que habla)
- La voz se digitaliza en el transmisor y se envía en paquetes.
- Convergencia de las redes de telefonía y datos.

-La voz se digitaliza (muestreo + cuantificación + codificación), se divide en paquetes y se envía por la red como cualquier otro dato.

-Convergencia de redes:

-ANTES:

Voz: RTC/RDSI (conmutación de circuitos)

Datos: Internet

-AHORA (con VoIP);

Todo viaja por la misma red IP (voz, vídeo y datos).



- Evolución:

- Primeras pruebas en 1973 (Network Voice Protocol sobre Arpanet).
- Despliegue a partir los años 90.
  - 1991: Se lanza la primera aplicación de VoIP, Speak Freely.
  - 1994: Aparece MTALK, una aplicación freeware de VoIP sobre Linux.
  - 1995: Intel y Microsoft comienzan con la estandarización de VoIP.
  - 1999: Se lanza el RFC de SIP.
  - 1999: Aparece Asterisk.
  - 2003: Se lanza Skype.
  - 2004: Aparecen múltiples proveedores de VoIP.
  - 2011: Google libera WebRTC (VoIP a través de navegadores).

- 2011–2015
  - Migración de PBX físicas a IP-PBX o PBX en la nube.
- 2016–2020:
  - WebRTC se consolida.
  - WhatsApp, Telegram, Zoom, Discord y Teams popularizan la VoIP.
- 2020–2025:
  - Se integran funciones de IA: cancelación de ruido, transcripción y traducción en tiempo real.
  - APIs de voz como Twilio o ElevenLabs permiten bots y asistentes inteligentes.

## ■ Motivos éxito

- Expansión de las redes de datos
- Disminución de los costes
  - Menor inversión inicial
  - Administración y mantenimiento de la red
  - Para el usuario final
- Estándares abiertos e internacionales
  - Interoperabilidad
  - Posibilidad de desarrollar nuevos servicios y aplicaciones por terceros
- Mayor flexibilidad e integración con otros servicios
- Calidad similar a la RTC
  - Casi todas las llamadas entre grandes operadoras usan VoIP
  - La fiabilidad no es mala


- Inconvenientes

- Necesidad de conexión de datos.
- Ancho de banda suficiente también en el uplink. Hablar no es solo descargar → la voz se envía y se recibe.
- Las redes de datos no están diseñadas específicamente para voz.


- Desafíos:

- Garantizar latencia baja La voz debe llegar rápido; si tarda demasiado, hay retardo molesto.
  - Jitter: variación en el retardo con que llegan los paquetes.
- Paquetes no llegan en orden y pueden perderse.
- Preservar ancho de banda
  - Trade-off entre ancho de banda y QoS. Hay que equilibrar:  
-menos ancho de banda → peor calidad  
-más calidad (QoS) → más consumo
- Seguridad.

## Arquitectura de la RTC



## Arquitectura en VoIP



- Sobre el retardo:

- En VoIP, además de retardo de transmisión hay retardo de procesamiento. digitalizar voz, comprimir, empaquetar, desempaquetar..
  - Aceptable hasta 150 milisegundos
  - A partir de 300 milisegundos se pisan conversaciones
  - A partir de 500 milisegundos es demasiado molesto
    - Necesario algún tipo de acuerdo entre usuarios: “Cambio”, “Corto” ...
- Se necesita buffer en recepción (también para paliar el Jittering).

Buffer grande (El buffer arregla los cortes esperando paquetes, pero esa espera añade retardo):

- Espera más tiempo antes de reproducir.
- Da tiempo a que lleguen los paquetes retrasados
- Voz más continua, sin cortes
- Escuchas la voz con más retraso

## 1. Funcionamiento general de una llamada

### 1. Usuarios registran sus teléfonos en servidor de VoIP

- Un usuario puede usar diferentes dispositivos
- Se asocia IP/puerto a ese usuario


### 2. Llamada

1. Emisor pregunta por el receptor
2. Servidor VoIP devuelve datos del receptor
  - » IP, Puerto, capacidades, ...
3. Establecimiento de la comunicación

El registro del usuario en el servidor es el proceso del escenario del registro de usuario en SIP.




SIP (Session Initiation Protocol) es el protocolo más extendido para establecimiento y control de sesiones en VoIP:



## ■ Terminales

- Teléfonos IP
- Softphones (Linphone)
- Adaptadores analógicos



Permiten usar teléfonos tradicionales en VoIP.

- ATA (Analog Telephone Adapter)
- Gateways VoIP

Convierte la señal analógica del teléfono en paquetes IP.

se usan para conectar redes telefónicas tradicionales (RTC) con redes VoIP.





FXS-puerto que va hacia tu teléfono.  
suministra energía y tonos al teléfono

FXO-puerto que va hacia la central telefónica o hacia la red RTC.  
recibe la señal de teléfono y la comunica a la central

## ■ Puertos analógicos (FXO/FXS)

### – FXS (Foreign eXchange Subscriber) (*extensión hacia el abonado*)

- Proporciona el tono de marcado
- Suministra tensión (y corriente) al dispositivo final

- ej. PTR (Punto Terminación de Red)


El PTR permite probar la línea de la operadora  
desconectando la red interna del abonado para verificar  
dónde reside un fallo físico.

### – FXO (Foreign eXchange Office) (*extensión hacia la central*)


- Envía información de
  - Colgado
  - Descolgado (cierre de bucle)

# VoIP

Enviar llamadas desde VoIP a RTC  
Necesitas gateway FXO.FXO  
“simula” un teléfono tradicional  
para que la central RTC lo  
reconozca.



Conectar un teléfono tradicional a  
una IP PBX (VoIP). Necesitas  
gateway FXS.FXS da tensión  
y tono al teléfono analógico para  
que funcione con VoIP.



- Si queremos enviar llamadas por RTC, necesitamos un gateway FXO para “simular” un teléfono tradicional.
- Si queremos conectar un teléfono tradicional a un IP PBX, necesitamos un gateway FXS.

## ■ Tecnologías:

### – Codecs

- Proceso de digitalización de la voz humana para transmisión digital en paquetes.

### – Protocolos

- Negociado y establecimiento de comunicaciones.
- Transporte de datos.

***La codificación es el proceso que convierte la señal analógica de voz en una representación digital optimizada para transmisión o almacenamiento, manteniendo la inteligibilidad y calidad perceptual con el menor ancho de banda posible.***

- Fundamentos:
  - Aparato fonador humano
    - Frecuencias, resonancias..
  - Características del cerebro en audición.
    - Completado de información.
    - Limitaciones auditivas
      - Mas sensibles a frecuencias bajas.
      - Filtrado natural de ruido y redundancia.

# Codificación

- Criterios de evaluación de un codec:.

Un codec es un software que comprime la voz para que ocupe menos espacio en internet. Abreviatura de Codificador-Decodificador.

Un códec (coder–decoder) es el algoritmo que decide cómo se generan y usan esos bits en el proceso de codificación.

-BER (Bit Error Rate): porcentaje de bits erróneos.  
A mayor BER → peor calidad percibida.

-SNR (Signal to Noise Ratio): relación señal/ruido.  
Mayor SNR → mejor calidad

-PESQ: métrica objetiva que estima el MOS comparando señal original y recibida.

-MOS (Mean Opinion Score): valoración subjetiva (1–5) basada en oyentes humanos.


## Calidad de la señal

BER (Bit Error Rate)  
SNR (Signal to Noise Ratio)  
PESQ (Perceptual Evaluation of Speech Quality)  
MOS (Mean Opinion Score)

## Eficiencia

Tasa de compresión

Más compresión → menos ancho de banda, pero mayor complejidad y posible pérdida de calidad.



## Retardo

Compresión/descompresión  
Transmisión  
Jitter

## Complejidad

Memoria, potencia (mW), Operaciones/seg

# Codificación


Codecs basados en la codificación de las muestras PCM.

Envían la voz “tal cual suena” -> Envío la forma de la onda de la voz

VS

Codecs basados en la codificación de parámetros del habla.

Envían cómo se produce la voz, no la voz en sí -> Envío instrucciones para reconstruir la voz



# Codificación

## 1-CODECS BASADOS EN LA CODIFICACIÓN DE MUESTRAS PCM

- Codecs de la serie G del **ITU-T** (*International Telecommunication Union – Telecommunication Standardization Sector*) esto es una familia de estándares de códecs de VOZ
  - G.701/G.711 (1972) 64 kb/s, alta calidad, bajo coste computacional.
    - PCM.
    - Cuantificación lineal/logarítmica: G.701/G.711.
    - Logarítmica con ley A ó ley  $\mu$ .
    - 64 kb/s.
    - Poco coste computacional.
  - G.721 (1984) 16–40 kb/s, buena calidad.
    - ADPCM (Adaptive Differential PCM)
      - Se adapta el paso en la cuantificación
      - 16 kb/s, 24 kb/s, 32 kb/s.
      - Calidad similar G.711.

# Codificación

- G.722 (1988) 48–64 kb/s, excelente calidad, muestreo 16 kHz.
  - Patentes caducadas, se puede usar libremente.
  - Muestreo a 16 khz, muestras de 14 bits: 224 Kbps.
    - Codifica señales de audio de hasta 7 kHz (por el muestreo).
    - Excelente calidad (mejor que G.711).
  - Descompone la señal en dos bandas de 4 kHz.
    - A cada banda le aplica ADPCM (Sub-Band ADPCM).
  - Tasas de bits finales: 48, 56 y 64 kb/s.
- G.723 (1988), G.726 (1990), G.727(1990) 16–40 kb/s, buena calidad.
  - Evoluciones de G.721, todos usan ADPCM.
  - G.723 fue una optimización, y G.726 vino a unificarlos.
  - G.727 introdujo una adaptación dinámica.
  - Son mas costosas computacionalmente que G.721.

# Codificación

## 2-CÓDECS BASADOS EN PARÁMETROS DEL HABLA

- Técnicas para codificar la voz basadas en parámetros:

- LPC (Linear Predictive Coding) (1960-70) Predice la siguiente muestra basándose en las anteriores y transmite solo los parámetros del modelo.
  - Define un modelo analítico del aparato fonador.
    - Formantes: bandas de frecuencia donde se concentra la mayor parte de la energía de un sonido.
    - Residuo: resto de elementos que conforman el sonido (nasalidad, flujo de aire, etc.).
  - Reduce cada segmento de audio a los parámetros del modelo que más se aproximan al original.
  - El decodificador recibe estos parámetros y sintetiza la voz correspondiente.
  - Implementaciones como LPC-10E pueden bajar hasta 2.4 kbps, pero la voz suena robótica.

Envía parámetros  
del habla, muy bajo  
bitrate (2.4 kb/s),  
voz robótica.

– Trasfondo matemático de LPC:

- Se parte de la señal discreta en tiempo (las muestras)
- Se divide en intervalos (10-30 ms). Se supone que las características del habla no cambian en ese intervalo.
- Se predice cada muestra con una serie de parámetros:

$$\bar{x}(n) = \sum_{k=1}^p a_k x(n-k)$$

- Se estima el residuo, la diferencia entre la estimación y el valor real:

$$e(n) = \sum_{i=1}^N |x(i) - \bar{x}(i)|$$

# Codificación

- Se determina los parámetros que minimizan el error (modelo matemático).
- Se transmiten los parámetros  $a_k$ 
  - $p \approx 10$  o  $12$  (mujeres / hombres)
- El residuo no se envía, pero se usa para indicar como es la excitación.
- En recepción, se obtiene la señal:

$$\hat{x}(n) = \sum_{k=1}^p a_k \hat{x}(n-k) + r(n)$$

- La excitación  $r(n)$  se modela en recepción como un ruido, en base a las características del residuo enviadas.

- CELP (Code Excited Linear Prediction) Mejor que LPC, usa un code-book de excitación, voz más natural, bitrate ~4.8–8 kb/s.
  - Es una versión mejorada del LPC. para que la voz no suene tan robótica
  - Se utiliza el error para mejorar el proceso de sintetización.
  - Existe un code-book de secuencias predefinidas de excitación conocida en tx y rx. Una lista de pequeños fragmentos de sonido predefinidos que tanto el emisor como el receptor conocen. En vez de inventar toda la excitación, elige el fragmento que más se parece al original.
  - Se elige aquella que produce una señal más parecida a la original.
  - Se envían los parámetros y la versión comprimida de la excitación (índice codificado).
  - Tasa de bits de hasta 4.8 kbps (con calidad similar a G.721 a 32 Kbps).
  - Muchos codecs usan variantes de CELP.

# Codificación

- Algunos codecs basados en la codificación de parámetros:
  - G.729a (1996) es muy eficiente en red, pero requiere algoritmos complejos (CS-ACELP) que consumen más CPU.
    - CS-ACELP (Conjugate Structure-Algebraic Code Excited Linear Prediction).
    - Calidad cercana a G.711 con solo 8 kb/s.
    - Sin patentes desde 2017
    - Muy eficiente y tolerante a fallos.
    - Todavía mas coste computacion
  - G.722.2 (2002)
    - Basado en ACELP
    - Optimizado para banda ancha, hasta 7khz (muestreo 16 khz)
    - Modo adaptativo, puede cambiar el bitrate según la red.
    - A 12.65 kb/s ofrece una calidad similar a G.722 (64 kb/s).
    - Mas usado en telefonía móvil 3G, 4G, 5G.

# Codificación

- ILBC (Internet Low Bitrate Codec) (2002)
  - Basado en LPC.
  - Diseñado para resistir pérdidas de paquetes.
  - Algoritmos complejos
    - Coste computacional similar al G.729A
  - Bitrates 13.3 Kb/s y 15.2 Kb/s
  - Sin coste de licencia
    - Desde 2011 open source (BSD).
- Speex (2003)
  - Basado en CELP
  - Codec de Bitrate variable (VBR)
    - Bitrate dependiente de las condiciones de la red
    - 2.15 a 22.4 Kb/s
  - Open Source BSD
  - Puede muestrear a 8,16 y 32 khz.

Eficientes, toleran pérdida de paquetes, bitrates bajos.

# Codificación

- OPUS (2012) Códec moderno y adaptativo, no depende solo de muestreos fijos y funciona con bitrate variable, que se ajusta automáticamente según la red. puede dar calidad casi igual o mejor que PCM, usando menos bitrate, porque solo transmite lo que importa para que la voz suene natural.
  - Diseñado para sustituir a los anteriores, se usa en WebRTC, Discord, Whatsapp,..
  - Utiliza dos tecnologías:
    - SILK, de Skype: especializada en voz humana.
    - CELT, de Xiph.Org: especializada en audio de alta calidad y baja latencia.
    - El codec detecta automáticamente y usa una, la otra, o ambas.
  - Muestreo a 8,12, 16,24 o 48 khz.
  - Bitrate 6 kb/s – 510 kb/s
  - Libre, licencia BSD.

# Codificación

- **MOS** (Mean Opinion Score): métrica a partir de pruebas de escucha con personas.

| MOS | Quality                | Impairment                   |
|-----|------------------------|------------------------------|
| 5   | Excellent              | Imperceptible                |
| 4   | Good                   | Perceptible but not annoying |
| 3   | Fair<br><i>regular</i> | Slightly annoying            |
| 2   | Poor                   | Annoying                     |
| 1   | Bad                    | Very annoying                |


| User Satisfaction             | MOS |
|-------------------------------|-----|
| Very Satisfied                | 4.4 |
|                               | 4.3 |
| Satisfied                     |     |
|                               | 4.0 |
| Some Users Dissatisfied       |     |
|                               | 3.6 |
| Many Users Dissatisfied       |     |
|                               | 3.1 |
| Nearly All Users Dissatisfied |     |
|                               | 2.6 |
| Not Recommended               |     |
|                               | 1.0 |

# Codificación


| Año         | Tasa de bits (kb/s) | Nombre / Estándar    | Tipo de codificación | MOS aprox. |
|-------------|---------------------|----------------------|----------------------|------------|
| <b>1972</b> | 64                  | <b>G.711 PCM</b>     | PCM                  | 4.4        |
| <b>1976</b> | 2.4                 | <b>LPC-10</b>        | LPC                  | 2.7        |
| <b>1984</b> | 32                  | <b>G.721 ADPCM</b>   | ADPCM                | 4.1        |
| <b>1988</b> | 64                  | <b>G.722</b>         | SB-ADPCM             | 4.3        |
| <b>1990</b> | 16–40               | <b>G.726 / G.727</b> | ADPCM                | 4.0        |
| <b>1992</b> | 16                  | <b>G.728</b>         | LD-CELP              | 4.0        |
| <b>1995</b> | 8                   | <b>G.729A</b>        | CS-ACELP             | 4.2        |
| <b>1995</b> | 6.3 / 5.3           | <b>G.723.1</b>       | ACELP                | 3.9        |
| <b>1999</b> | 6.6–23.85           | <b>G.722.2</b>       | ACELP adaptativo     | 4.4        |
| <b>2002</b> | 13.3 / 15.2         | <b>iLBC</b>          | LPC                  | 4.0        |
| <b>2003</b> | 2–44                | <b>Speex</b>         | CELP                 | 4.0        |
| <b>2012</b> | 6–510               | <b>Opus</b>          | SILK + CELT          | 4.5–4.6    |

# Codificación

- **PESQ** (Perceptual Evaluation of Speech Quality): método automatizado que compara la señal antes y después de codificar, y genera un MOS objetivo.



# Codificación



## ■ Señalización

- Localizar destino
- Negociación de parámetros de conexión
- Establecimiento de la conexión
- Control y gestión de la llamada

## ■ Transporte

- Orden de los paquetes
- Retardos
- Pérdida de paquetes

- Protocolos que hacen posible la transmisión de voz sobre redes IP:
  - Señalización
    - SIP (Session Initiation Protocol)
    - H.323
    - IAX (Inter-Asterisk eXchange)
  - Transporte
    - RTP (Real-time Transport Protocol)

- H.323 El Gatekeeper es el servidor central de control en una red H.323 (telefonía sobre IP antigua).• Es el “cerebro” de la red H.323.
  - Originalmente para videoconferencia en redes LAN
    - 1996 por el ITU (International Telecommunications Union)
  - Señalización para transmisión de contenido multimedia sobre redes de paquetes
    - Válido para voz, audio y vídeo, con RTP.
  - Complejo, basado en binario.
  - QoS integrado
  - Actualmente “en desuso”
    - Restringido a grandes fabricantes (p.e. Cisco) y operadoras.


## ■ Session Initiation Protocol (SIP)

- El más extendido
  - Aprobado en 1999 IETF (Internet Engineering Task Force)
  - Destronó rápidamente al H.323
- Protocolo simple
  - Sintaxis comparable a HTTP (basado en HTTP)
  - Modelo cliente-servidor con esquema petición-respuesta
- Utilizado para establecimiento, modificación y finalización de sesiones
  - Válido para señalización de voz, audio y vídeo
- Usa SDP y RTP
  - Los mensajes SDP (negociado de parámetros) son enviados a través de SIP
  - Los mensajes de datos se envía con RTP
- Puertos TCP y UDP 5060

# Protocolos

## – Capacidades

- Localización usuario
- Disponibilidad usuario
- Capacidad usuario
- Gestión de la sesión
  - Establecimiento, transferencia, terminación, modificación de parámetros
  - ...
- Habilita movilidad de usuarios (registro)
  - Un usuario puede usar diferentes teléfonos



## – Servidores proxy

- Se encargan de gestionar el enrutado de llamadas y la señalización entre clientes.

# Protocolos


- SIP no se encarga del streaming de audio y video.
  - Para eso se usa RTP
- Problemas con NAT
  - Las direcciones para enviar el contenido multimedia se envían en el cuerpo del mensaje, y serán normalmente IPs privadas.
  - Opciones:

Servidor intermedio  
(Proxy/RTP)

Proxy RTP público

VPN

- Pasar el tráfico RTP por el proxy (p.ej. servidor Asterisk).
- Usar un proxy RTP en una dirección pública accesible para todos.
- Una VPN.



- Inter-Asterisk eXchange Protocol (IAX2)
  - Diseñado para voz en centralitas Asterisk
  - Protocolo abierto
    - Inicialmente desarrollado por Digium
    - Utilizado por múltiples proyectos y fabricantes
      - Pero sobre todo Asterisk
  - Solo necesita un puerto: UDP 4569
    - Vale para señalización y transmisión del contenido multimedia, aunque normalmente solo voz.

- Mas sobre IAX2:
  - Facilidad para trunking
    - Múltiples sesiones en un solo flujo
      - Reducción del overhead, menos cabeceras que enviar.
  - No tiene problemas con NAT.
    - Paquetes de datos multimedia pasan a través del servidor.

Al combinar todo en un solo puerto y flujo, se evita el problema de SIP donde el audio (RTP) suele usar puertos dinámicos que el NAT bloquea.

## ■ Real-time Transport Protocol (RTP)

- Basado en sesiones
  - Dirección IP
  - Dos puertos: datos y control (RTCP)
  - Puertos UDP del 10.000 al 20.000
- Sesiones separadas para cada media
  - P.e. Dos sesiones para audio y vídeo
- QoS
  - Garantiza orden paquetes
  - Mecanismos para preservar latencia/jitter bajo
  - Seguridad: encriptación e integridad de datos
- Paquetes
  - Cabeceras RTP identifican el codec utilizado
- Audio conferencia con multicast

# Protocolos

## – Mixers

- Permiten la participación de usuarios con poco ancho de banda
  - Hacen conversiones de códec necesarias
- Los *streams* de varios usuarios se combina en un único *stream*

## – Translators

- Permite el uso de otros protocolos de transporte (transport translator)
  - » Permiten conexión de usuarios sin capacidad multicast
- Traducción de códecs (media translator)

## ▪ RTP Control Protocol (RTCP)

### – Envío periódico de paquetes de control

- Destino a los participantes de una sesión multimedia
- Información sobre la calidad de servicio
  - Número de participantes, latencia, paquetes perdidos, ...
  - Uso de la información para mejorar la QoS
  - Negociación de parámetros y formatos

# Extra – Telefonía móvil

| Generación       | Tipo de transmisión | Dónde se digitaliza la voz | Tipo de red                | Códecs principales  |
|------------------|---------------------|----------------------------|----------------------------|---------------------|
| <b>1G</b>        | Analógica           | No digitalizada            | Conmutación analógica      | —                   |
| <b>2G (GSM)</b>  | Digital CS          | En el terminal             | Circuitos digitales (TDM)  | GSM-FR, EFR, AMR-NB |
| <b>3G (UMTS)</b> | Digital híbrida     | En el terminal             | CS + transporte IP interno | AMR-NB/WB           |
| <b>4G (LTE)</b>  | IP                  | En el terminal             | Transporte IP              | AMR-WB, EVS         |
| <b>5G (NR)</b>   | IP                  | En el terminal             | Transporte IP              | EVS                 |

# Extra – Telefonía móvil

- Codecs telefonía móvil:
  - GSM-FR (Global System for Mobile Communications Full Rate) (1991)
    - Basado en LPC
  - GSM-EFR (GSM Enhanced Full Rate) (1996)
    - Mejora el MOS del anterior.
    - Basado en CELP, similar a G.729a
  - AMR-NB (Adaptive Multi-Rate Narrowband) (1999)
    - Tipo ACELP, similar a G.729.1 o Speex.
    - Bitrate adaptativo.
    - Detección de voz, eliminación de ruido..

# Extra – Telefonía móvil

- AMR-WB (AMR Wideband) (2001)
  - Como AMR-NW pero hasta 7khz.
  - G.722.2 es la versión ITU de AMR-WB.
  - Voz HD.
- EVS (Enhanced Voice Services) (2014)
  - Similar a OPUS, una tecnología para voz, otra para audio, se pueden combinar.
  - La de voz ACELP.
  - Hasta 20khz.